Statistical PO on ML

data analysis ⇒ discover {unknown / valid / useful / understandable} knowl. from data.
⇒ large datasets (intern. R / struct, clusters, visu...)

Why ana. data → soc. need but data = big + many
⇒ ex: pred° natur. disast, med°, finance...
↓ ex tasks: regress°, cluster
⇒ desc + classify + segm° + hypo + build modL + pred°
cheaper + powerful

learning → general + cplx
→ acquire knowl. skills...
general simplicity → razor → linear > high deg poly
absorpt° / compreh. / app } info
ML (CAI) → learning
↓ dev algo + modL
↓ learn + improve without prog.

from → ex:
- stud specific instances
- recog pattern / regularit.
ML: dev rules
supervised: labeled train data
⇒ patt I/P & O/P
⇒ pred°/classif° on unseen

explor°:
- new approach
- interact with env
ML: opti behav by trial & error
reinforcemt: env, feedback, rewards (maximising)

observ°: - imitat°
ML: patt mimick
unsupervised: algo disc. patt R in data without labL
⇒ clustering / ↓ dim
⇒ uncov. patt.

Statistical learning = ML + stat

desirable prop of model → generaliz°
- perf well on unseen data
- test set
- ~~mono~~ learn
↓ interpret + stability
↘ robustness & scalab.
- resist to outliers/noise
- handle larger/cplx data
- adapt to evolving data

hypo space (= all possib res of algo)
∪
version space (= hypo coherent consistent with data)
∪
models space (= specific learned vers°)

Bias Err
↳ low cplxT modL
⇔ simplified assumpt°
↳ underfit on data (underlying)
= +++ bias / --- var
Var Err
↳ high cplxT modL
⇔ sensi to fluct° in training data
↳ overfitting = --- bias / +++ var

Bias-Var Trade off (compromis)
⇒ mini Err

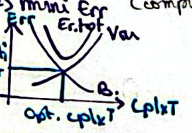

good trade off ⇒ good generaliz°
⇒ under/overfit balance ⇒ right cplxT

learning strat:

① **Init Guess** → arbit/predef value θ_0
↓ **Training Err**: comp pred°/true val; $\frac{1}{N}\sum_{i=1}^{N} L(y_i, \hat{f}(x_i,\theta))$
② **Learned Model** → O/P of ML after trained on dataset $\hat{f}(x,\theta)$
↓ **Opt° Err**: diff btween train err & ERM: $Err_{train}(\theta_{ERM}) - E_{train}(\theta)$
③ **Emp Risk Min** → min avg loss on given dataset: $\hat{\theta} = \arg\min \frac{1}{N}\sum_{i=1}^{N} L(y_i, \hat{f}(x_i;\theta))$
↓ **Gen Err**: err on unseen data: $\mathbb{E}_{test}[L(y, \hat{f}(x,\theta))] = GenErr(\theta)$
④ **Best Model** → optimally fits given data (lowest Gen Err) $\arg\min_{\theta} GenErr(\theta) = \hat{\theta}_{best}$
↓ **Approx Err**: modL's inability to repres true R betw I/P & O/P
⑤ **Target** → desired O/P a model aims y
$ErrGen(\hat{\theta}_{best}) - ErrGen(\hat{\theta})$
① → ④ ∈ Model space ; App Err + Target ∈ Vers° space.

Algo → K-nn: - $D_N = \{(X_i, Y_i)\}$; $y_i \in \{-1, 1\}$ ↳ classif° pb (pas in R)
↳ proximity
↳ la clas la + repres parmi les k ~~docs~~ voisins x_i est donnée à x
↳ petit k ⇒ sensi bruit / gd k ⇒ biais pour clas maj
dim trop gde ⇒ tem proche/loin ⇒ k ⊕ sensi
↳ ne voit que 2 copc?

Minimal Formal Model:
Supervised learning Cntxt ⇒ model capable of ~~fering~~ O/P from I/P data
⇐ estim f° linking I/P to O/P using observ° from X, Y from unknown Joint Distb.
⇒ generaliz° on unseen.
ΔML pb: 1st modL that generalize beyond training data ⊕ quantify accuracy of pred°
loss F°: quantify discrepancy/penalty betw pred° $g(x)$ & true val y
⇒ eval model.
↓ Δ in supervised learning ⇒ opti para ⇒ guide training process.
⊖ L f° ⇒ decis° making found

minimising loss f° ⇒ estim modL's f°
$g(x)$, y, x
Δ in classif° pb
→ ex: squared ↳ $L(y, g(x)) = (y - g(x))^2$
abs: $L(y, g(x)) = |y - g(x)|$
log-loss: $L(y, g(x)) = -[y \log(g(x)) + (1-y)\log(1-g(x))]$
challg choosing L f°
- cplxity / sensi to outliers / interpretability
⇒ trade offs.

Empirical Risk R_{emp} → avg loss on training data
⇒ eval modL perf. (how well model g fits data (train))
→ $= \frac{1}{N}\sum_{i=1}^{N} L(g(x_i), y_i)$
↘ construct° grad desc
sum of individ loss
↳ choice of L = Δ
goal: find g that min loss ⇒ min ER = Remp
training → generaliz° → Valid° to asses model perf
↳ ↓ Remp(g) ↳ eval g on unseen
⇒ prob approx tly correct
PAC learning framework ⇒ guarantee + high proba + bounded cplxT } that the model = approxtly correct!
≠ contxt ⇒ ≠ perpectives.
Asympto → modL's evol° as data size → ∞
↳ consistency.
Well def mdL = Δ ⇒ accurate pred° + understanding
Theorical guarantees ⇒ establish lim on error generaliz° capab.
↳ insights on modL perf ⊕ ~~convenance~~ cvg to true f°

loss funct°: $L : Y \times Y \to \mathbb{R}^+$; $\forall y \in Y, L(y,y) = 0$
$L(g(x), y)$ loss incurred when y replaced by $g(x)$
↳ $\forall i$, $L(g(x_i), y_i)$ should be as small as pssbl.
↳ ex: $Y = \mathbb{R}$ → $L_2(p,t) = (p-t)^2$; $L_1(p,t) = |p-t|$; $L_{APE}(p,t) = \frac{|p-t|}{|t|}$
$|Y| < \infty$; $L_b(p,t) = \mathbb{1}_{\{p \neq t\}}$
local scale
↳ gener ⇒ average loss
emp risk model g on D
$\hat{R}_L(g, D) = \frac{1}{N}\sum_{i=1}^{N} L(g(X_i), Y_i)$; $D = \{(X_i, Y_i)\}_{1 \le i \le N}$
$= \frac{1}{|D|}\sum_{(x,y)\in D} L(g(x), y)$
good model = $\hat{R}_L$ ↓

$Y = \{y_1, y_2\}$:

	$t = y_1$	$t = y_2$
$p = y_1$	0	$L(y_1, y_2)$
$p = y_2$	$L(y_2, y_1)$	0

matrice confus: $\hat{C}_{y,y'} = |\{i \in \mathbb{N} \mid g(X_i) = y \text{ and } Y_i = y'\}|$ = # ⊗ où g renv y au lieu de y'
qd $Y = \{-1, 1\}$ → $t_p = g(X_i) = \mathbb{1}_{\{Y_i = 1\}}$, $f_n = g(X_i) = \mathbb{1}_{\{-Y_i = -1\}}$
$\hat{R}_L(g, D)$ très petit ⊕ $\hat{R}_L(g, D) \lll \hat{R}_L(g, D')$ ⇒ overfitting
$D = \{(X_i, Y_i)\}_{i \le N}$ avec $(X_i, Y_i) \sim \mathcal{D}$ et $D \sim \mathcal{D}^N$ ⇒ iid
↳ risq théoriq: $R_L(g) = \mathbb{E}_{(X,Y)\sim\mathcal{D}}[L(g(X), Y)] = R_L(g, \mathcal{D})$
↳ risq empiriq: $\hat{R}_L(g, D) \xrightarrow[|D|\to+\infty]{a.s} R_L(g, \mathcal{D})$ (loi gd nb)
↳ best risk: $R_L^* = \inf_{g: X\to Y} R_L(g)$
↳ ML algo → universel
Emp risk min → consistent if $\mathbb{E}_{D\sim\mathcal{D}^N}(R_L(g_D)) \xrightarrow[a.s]{N\to+\infty} R_L^*$
if g ⫫ D, $\hat{R}_L(g, D) \xrightarrow[|D|\to+\infty]{a.s} R_L(g, \mathcal{D})$ or incalc car $\mathcal{D}$ inco donc
on use $\hat{R}_L$ pour minimiser risq
⇒ ML dev pb d'optim°: ERM: $g_{ERM} = \arg\min_{g \in G} \hat{R}_L(g, D)$
→ Δ if X_i distinct, $1nn(X_i) = i$ ⇒ $g_{1-nn}(X_i) = Y_i$ ⇒ $\hat{R}_L(g_{1-nn}, D) = 0$
cas 1-nn
$R_L^* \le R_1^* \le 2R_L^*(1 - R_L^*)$
M classes $= (2 - \frac{M}{M-1} R_L^*)$

protocole en app auto: ① split → D train / D' valid° hyperparam / D'' test
② model select° → ∀ algo A, ∀ set hyperpara θ: train $g_{A,\theta,D}$
③ eval $\hat{R}_L(g_{A,\theta,D}, D')$ ⇒ donne A* et θ*
④ ré-entraine sur $g^* = g_{A^*,\theta^*,D\cup D'}$
⑤ calcul $\hat{R}_L(g^*, D'')$

missing value → ignored / filled
→ simil ⇒ ↑ corr°
→ mean ⇒ ↓ dispers°
→ regress° ⇒ ↑ correl°
outliers → inconsistent / out of range
3 src d'err en ML → optimis° / estim° / approx°

PAC learning → starting pt = concept learning $c : X \to \{0,1\}$
- cas 1 k pt donner Y ≠ ; là non ↳ = f° indicat. determi
- $Y = c(X)$ = label parfait + determ ↳ f° loss $= L_p(p,t) = \mathbb{1}_{\{p \neq t\}}$
$(X,Y) \sim D$; $X \sim D_X$
⇒ $(X,Y) \sim (D_X, c(X))$
⇒ $R_L^* = 0$ (∅ bruit)
⇒ $R_g = \mathbb{E}_{X\sim D_X}[\mathbb{1}_{\{g(X) \neq c(X)\}}] = \mathbb{P}_{X\sim D_X}(g(X) \neq c(X))$
⇒ $\hat{R}(g, D) = \frac{1}{N}\sum_{i=1}^{N} \mathbb{1}_{\{g(X_i) \neq c(X_i)\}}$
cadre PAC: A = algo ; A(D) = modL après entaiN A sur D → ens d'hypo explorées
concept C est PAC learnable si: ∀c ∈ C, $\boxed{\forall D_X}$, ∀ε, ∀δ, dès que $N \ge \lceil N_C(\varepsilon, \delta) \rceil$ on a $\mathbb{P}_{D\sim D_X^N}\{R(A(D)) < \varepsilon\} \ge 1 - \delta$
↳ "cplxT d'ech" ; n'impq loi ; seuil err > 0 ; seuil confiance $0 < \delta < 1$
→ pr modèle 100% exact, 100% sûr → PAC fait 2 tolérances:
① approx correct ($\le \varepsilon$) ⇒ on demd pas err R = 0
② proba ($\ge 1 - \delta$) ⇒ on autorise petit risq d'echec δ.
lien ERM - PAC (cas concepts finis): c ∈ C ⇒ $R_C^* = 0$ ⇒ ERM select modèle tq $\hat{R}(g, D) = 0$
Si $|C| < \infty$; PAC ($R < \varepsilon$ avec proba $\ge 1-\delta$) ok dès que $N \ge \lceil \frac{1}{\varepsilon} \log \frac{|C|}{\delta} \rceil$

Scanned with CamScanner

Agnostic PAC learnability : - bruit ⊕ pas de f° loss fixe
- on supp plus que vrai modèle $\in G$

↳ G est PAC agno learnable si : pour $\in G$ ∃ f° $N_G : [0,1]^2 \to \mathbb{N}$: qd $N \geq N_G(\varepsilon, \delta)$ l'algo trv modl dont $R_L(A, D)$: $\mathbb{P}_{D \sim D_x^N}\{R_L(A(D)) \leq R^*_{L,G} + \varepsilon\} \geq 1-\delta$

approx° uniforme : pour que ERM marche avec bruit etc, ft que $\hat{R}_L$ = bonne esti de R_L $\forall g \in G$ en m̂ tps (approx° unif)

↳ $R_L(g_{ERM}, L, G, D) - R^*_{L,G} \leq 2 \sup_{g \in G} |R_L(g) - \hat{R}_L(g, D)|$ ⊖ qd écart petit entre R et $\hat{R}$

↳ déf N pr garantir écart > ε}

borner erreur pr clas finies de modèles : $|G| < \infty$ & $L \in [a,b]$ ⇒ qd $N \geq \left\lceil \frac{\log \frac{2|G|}{\delta}(b-a)^2}{2\varepsilon^2} \right\rceil$

alors $P_{D \sim D_x^N}\{\sup |\hat{R}_L(g, D) - R_L(g)| \geq \varepsilon\} \leq 1-\delta$

⇒ si $|G| < \infty$, $L \in [a,b]$, als ERM donne PAC agno learn avec $N_g(\varepsilon, \delta)$ =

pour classes ∞ = |G| : - bruit mes pb classif° binR avec $L = L_b$

↳ f° de croiss : compte nb de comport^t ≠ que ces f° pvt avoir sur ens fini ~~de~~ m pts $(v_1, \dots v_m)$:

$SG(m) = \sup_{\{v_1, \dots, v_m\} \subset X} |G_{\{v_1, \dots, v_m\}}|$ → S(G) pas expo. $SG(m)$ = # max de classif° sur m pts

↳ f° de croiss

↳ lien fort entre SG et général° :

$$\circledast \ \mathbb{P}_{D \sim D_x^N}\left\{\sup_{g \in G} |\hat{R}_L(g, D) - R_L(g)| \geq \frac{4 + \sqrt{\log S_G(2N)}}{\delta\sqrt{2N}}\right\} \leq 1-\delta$$

vapnik Chervonenkis → $VC\dim(G) = \sup\{m \in \mathbb{N} \mid SG(m) = 2m\}$

dimVC = m si m = taille max de pts tq G ∄ pulveriser (= tq modL ∄ app parfait ∀ config)

↳ lemme sauer : VCdim < ∞ ⇒ ∀ m > VCdim(G),   ↳ = pts étiq° parf

$$S_G(m) \leq \left(\frac{em}{VC\dim G}\right)^{VC\dim(G)}$$

→ chg pt ∈ {0 ou 1} ⇒ 2^m

passage de S(G) expo à poly

dimVC < ∞ (= d) ⇒ gén° : ⊛ car S(G) est poly !! c ce qu'on voulait

$G = \{g : X \to \{0,1\} \mid \exists f \in F, \forall x \in X, g(x) = \mathbb{1}\{f(x) \geq 0\}\}$

↳ ep vect des f° $X \to \mathbb{R}$ de dim p

⇒ $VC\dim(G) \leq p$.

→ G clas mod $g : X \to \{0,1\}$ ⇒ G agno PAC learnbl avec $L = L_b$
⟺ ERM donne agno PAC learn avec L_b
⟺ dim VC(G) < +∞

⇒ dim VC = nécessR & suffisante pour app (learnability)

⇒ si dim VC = ∞ ⇒ modèle pt pas généraliser (sauf si restrict°/régular°)

ERM in practice (trv g_{ERM} qui min $\hat{R}_L$)

↳ choix de classe G, ex modL clas binR ($Y = \{-1, 1\}$)

↳ ① modL base fixée : préd° = $\mathrm{sgn}(\sum \alpha_k f_k(X))$ algo app que sur → poids ↲ fixées + prédef

↳ aussi pr $Y = \mathbb{R}$ (enlever sgn)

but d'app = résd pb d'opti° = trv arg g (= para) qui minim $\hat{R}_L$

↳ ② modL base para : préd° = $\mathrm{sgn}(\sum \alpha_k f_k(w_k, X))$ algo app sur poids glob α_k et sur para interne w_k ajusté par para

→ cas facile = regress° linR - modL = comb linR des entrées - f° perte = L_2 (convexe)

↳ sol° = $\beta^* = (X^T X)^{-1} X^T Y$

cas dur = classif linR avec perte (0-1) $O(NP^2)$ (au car bruit ⊕ err = exist) ↳ # données ≠ var

↳ sol° = descente de grad standard

↳ smooth f° (f° perte dériv) remplace f° escalier ⊕ modL para dérivables. ⇒ calc grad de perte

batch ↳ $w^t = w^{t-1} - \gamma^t \nabla \hat{R}_L$ → calc dse exacte vers min → en ust tout dataset à chq itér° ⇒ lourd

↳ desc. grad stochastiq = tire aléat^t 1 exemple du dataset à chq itér° pour estim grad + màj para

→ autres méthodes (heuristiq)

↳ opti cert^2 para, fixer les autres

maxi likelihood f° = ERM disguised ⇒ estim para

↳ ex regress° linR si $Y_i | X_i = X \sim \mathcal{N}(\beta_0 + \beta^T X, \sigma^2)$

als MLE de β_0 et β : $(\widehat{\beta_0, \beta}) = \arg\min(Y_i - \beta_0 - \beta^T X_i^2)$

donc MLE = ERM.

↳ ex regress° logistq : $Y = \{0, 1\}$

↳ modL stat estim proba d'∈ C via β_0, β

↳ MLE ⇒ maxi log vraisemblance

↳ ERM ⇒ ~~modélise direct~~ mais prédit nbR et f° perte adaptée ⇒ comp à vraie étiquette.

relaxat° → pdt train on dem plus décis° binR

↳ on demd score continu ⇒ ±± f° perte dérivbl qui calc quali du score à vraie classe. ⇒ dét classif° finale.

↳ ex de f° perte relaxées :

↳ L_{logi} (régress° logistq)

↳ $L_{Hinge} : \ell(p, t) = \max(0, 1 - pt)$ (SVM)

↳ L_{expo} : (adaboost)

↳ $L_{perceptron} : \ell(p, t) = \max(0, -pt)$.

⊖ en classif° binR. $\mathbb{E}_{D \sim D^N}(R(g_D)) \geq \frac{1}{2e} - \varepsilon$

① dim VC(G) = ∞ → m̂ si $R_G^* = 0$; err moyN ∄ $\hat{e} > \frac{1}{2}$

② dim VC(G) < ∞ → ∃ distrib où err d'approx° reste incompressbl ($R_G^* - R^* > 1/2 - \varepsilon$)

apprentissage garanti

Scanned with
CamScanner