Exercice 1. *In this exercise, we study a classification problem in which the target variable Y can take three different values in $\mathcal{Y} = \{A, B, C\}$. From a learning set $\mathcal{D}$, two models have been constructed g_1 and g_2. Their predictions on a new set $\mathcal{D}'$ are summarized by the following confusion matrices (we use the convention that the predicted values are in rows while the true values are in columns):*

g_1	A	B	C
A	44	0	0
B	5	62	1
C	1	8	54
	50	70	55

g_2	A	B	C
A	44	4	5
B	2	64	3
C	4	2	47
	50	70	55

Questions :

1. *Using the confusion matrices, compute an estimation of the distribution of Y, i.e. of the probabilities $P(Y = y)$ for $y \in \mathcal{Y}$.*

Pour g_1, d'après la matrice de confusion :
- → on a 50 observ° dont la vraie étiquette est A sur 175 obs° tot.
- → ——— 70 ——————————— B ———————
- → ——— 55 ——————————— C ———————

Calculons $P(Y = y)$ avec $y \in \{A, B, C\}$:

- → $P(Y = A) = 50/175 = 0{,}29$
- → $P(Y = B) = 70/175 = 0{,}4$
- → $P(Y = C) = 55/175 = 0{,}31$

Pour g_2 : idem car $\mathcal{D}'$ est le même (donc vraies classes identiques mais prédictions ≠)

2. *What minimal consistency checks between $\mathcal{D}$ and $\mathcal{D}'$ should be done?*

Il faut :
- * $\mathcal{D} \perp\!\!\!\perp \mathcal{D}'$
- * même variables (# col, etc)
- * même ens de labels
- * même distribut° (comparables)

3. *Compute the accuracy of each model on $\mathcal{D}'$ (the accuracy is the percentage of correct classification).*

→ # bonnes pred / nb pred (ex $\frac{TP+TN}{TP+TN+FP+FN}$)

accuracy de g_1 : $(44+62+54)/175 = 160/175 = 0{,}91$.
accuracy de g_2 : $(44+64+47)/175 = 155/175 = 0{,}89$

4. *Determine the best model between g_1 and g_2 according to the loss function $L_b(p,t) = \mathbf{1}_{p \neq t}$. using the empirical risk on $\mathcal{D}'$.*

$L_b(p,t) = \mathbb{1}_{p \neq t}$

Donc $\hat{R}_L(g_1) = (6+8+1)/175 = 15/175 = 0,09$
$\hat{R}_L(g_2) = (6+6+8)/175 = 20/175 = 0,11$

le modèle qui minimise le risque empirique est g_1
donc c'est le meilleur modèle d'après $L_b(p,t) = \mathbb{1}_{p \neq t}$ sur $\mathcal{D}'$.

5. *Is the selected model the best one according to the risk associated to L_b ?*

On peut pas le confirmer car risque empirique = estimation du risque réel et sachant que $|\hat{R}_L(g_1) - \hat{R}_L(g_2)| = 0,02$ est très faible sachant que nb total d'observat° = 175.

6. *We define a new loss function ℓ_2 as follows:*

$\ell_2(p,t)$	A	B	C
A	0	2	1
B	1	0	1
C	2	1	0

We use the convention that p is the predicted value and t the true value. Compute the empirical risk of each model according to this loss function on $\mathcal{D}'$.

Pour ça on multiplie terme à terme mat confus° et mat de coût

$\hat{R}_L(g_1)$:
→ Pour A : 44 x 0 + 0 x 2 + 0 x 1 = 0
→ Pour B : 5 x 1 + 62 x 0 + 1 x 1 = 6
→ Pour C : 1 x 2 + 8 x 1 + 54 x 0 = 10
Donc $\hat{R}_L(g_1) = 16/175 = 0,09$.

Pour $\hat{R}_L(g_2)$:
→ Pour A : 44 x 0 + 4 x 2 + 5 x 1 = 13
→ Pour B : 2 x 1 + 64 x 0 + 3 x 1 = 5
→ Pour C : 4 x 2 + 2 x 1 + 47 x 0 = 10
Donc $\hat{R}_L(g_1) = 28/175 = 0,16$.

Donc g_1 est aussi le meilleur modèle pour L_2.