Apprentissage Statistique - TP 4+TP5

M2 EI2D & MATD – Le 2 nov 2026

Instructions : Préparez un rapport incluant le code source et vos résultats, et déposez-le sur Teams. Pas plus de 2 personnes par groupe. N'oubliez pas de mettre les 2 noms sur le rapport, ou de faire 2 rendus. La date limite du rendu TP est le 16 nov 2026

Objectif du TP

Nous allons analyser un extrait de données réelles : le registre des passagers du Titanic.
Les données sont réparties en deux ensembles :
— `titanic_train.csv` : ensemble d'apprentissage ;
— `titanic_test.csv` : ensemble de validation.
Ces fichiers contiennent des informations sur les passagers : nom, sexe, âge, classe, prix du billet, port d'embarquement, etc.
L'objectif est d'étudier les facteurs associés à la survie des passagers, puis de construire plusieurs modèles de classification naïve bayésienne.
Nous comparerons leurs performances sur un ensemble de validation indépendant.

Bibliothèques Python

Nous utiliserons principalement :
— `pandas` pour manipuler les données ;
— `numpy` pour les calculs numériques ;
— `matplotlib` et `seaborn` pour les visualisations ;
— `scikit-learn` pour construire et évaluer les modèles de classification.
Les bibliothèques peuvent être importées comme suit :

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.naive_bayes import CategoricalNB
from sklearn.preprocessing import OrdinalEncoder
from sklearn.metrics import accuracy_score
from sklearn.metrics import confusion_matrix
from sklearn.metrics import classification_report
```

1 Analyse préliminaire

1. Charger le fichier `titanic_train.csv` dans un DataFrame `pandas`.

```
train = pd.read_csv("titanic_train.csv")
```

Décrire les différentes variables :
— Afficher les premières lignes du DataFrame.
— Identifier les types des variables.

— Afficher les statistiques descriptives.
— Représenter graphiquement la distribution des principales variables.
— Calculer la proportion de valeurs manquantes pour chaque variable.
On pourra notamment utiliser les méthodes `head()`, `info()`, `describe()`, `value_counts()` et `isna()`.

2. Combien de passagers sont décédés et combien ont survécu dans cet ensemble de données ?
— Afficher le nombre de survivants et de personnes décédées.
— Calculer les pourcentages correspondants.
— Représenter graphiquement la répartition des deux catégories.
On utilisera la variable `Survived` :

$$\texttt{Survived} = \begin{cases} 0 & \text{passager décédé,} \\ 1 & \text{passager survivant.} \end{cases}$$

2 Les femmes et les enfants d'abord !

1. Comparer les taux de survie des hommes et des femmes.
On pourra utiliser les méthodes `groupby()` et `mean()`.
Commenter les résultats.
2. Nous souhaitons maintenant étudier le taux de survie en fonction de l'âge des passagers.
— Créer une nouvelle variable `Child` prenant la valeur `"child"` si le passager a moins de 18 ans et `"adult"` sinon.
— Calculer le taux de survie en fonction de cette nouvelle variable.
— Commenter les résultats.
On pourra utiliser la fonction `np.where()`.
3. Quelle hypothèse potentiellement biaisée a été introduite dans la question précédente ?
Examiner en particulier le traitement des passagers dont l'âge est inconnu.
Proposer une solution pour corriger ce problème, puis recalculer les taux de survie.
Les résultats sont-ils sensiblement différents ?
4. Reprendre la variable `Child` définie à la question 2.
Calculer les taux de survie en fonction de la catégorie d'âge et du sexe.
Que peut-on conclure sur l'efficacité de la politique « Les femmes et les enfants d'abord » lors de l'évacuation du Titanic ?

Classification naïve bayésienne

Nous allons maintenant construire un premier modèle de classification naïve bayésienne pour prédire la survie des passagers à partir des variables `Sex` et `Child`.

Nous utiliserons la classe `CategoricalNB` de la bibliothèque `scikit-learn`.

5. Charger l'ensemble de validation :

```
test = pd.read_csv("titanic_test.csv")
```

Créer la variable `Child` dans les deux ensembles de données en appliquant la même règle.
Traiter les valeurs manquantes de manière cohérente.
Encoder les variables catégorielles `Sex` et `Child` sous forme d'entiers.
On pourra utiliser `OrdinalEncoder`.
Attention : l'encodeur doit être ajusté uniquement sur les données d'apprentissage, puis appliqué à l'ensemble de validation.
Vérifier que les deux ensembles utilisent le même codage.

6. Entraîner un classifieur naïf bayésien :

```
classifier = CategoricalNB()
classifier.fit(X_train, y_train)
```

où `X_train` contient les variables explicatives encodées et `y_train` contient la variable `Survived`.

Examiner les attributs :
— `classifier.classes_`
— `classifier.class_log_prior_`
— `classifier.feature_log_prob_`
Quelles probabilités représentent-ils ?

Comment ces probabilités sont-elles liées aux taux de survie calculés précédemment ?

Pourquoi parle-t-on de classification *naïve* bayésienne ?

7. Appliquer le modèle à l'ensemble de validation :

```
y_pred = classifier.predict(X_test)
```

— Comparer les prédictions aux véritables valeurs de la variable `Survived`.
— Calculer le taux de bonnes classifications avec `accuracy_score()`.
— Afficher la matrice de confusion.
— Commenter les erreurs du classifieur.

3 Taux de survie selon la classe sociale

1. Afficher les taux de survie des passagers pour chacune des trois classes (`Pclass`).
Commenter les différences observées.
2. Nous allons construire deux variables catégorielles.
— Traiter `Pclass` comme une variable catégorielle, même si ses valeurs sont représentées par des entiers.
— Créer une nouvelle variable `Fare2` à partir du prix du billet `Fare`, selon les catégories suivantes :
— `"<10"` : prix inférieur à 10 ;
— `"10-20"` : prix entre 10 et 20 ;
— `"20-30"` : prix entre 20 et 30 ;
— `"30+"` : prix supérieur ou égal à 30 ;
— `"NA"` : prix manquant.

On pourra utiliser la fonction `pd.cut()` pour discrétiser les valeurs numériques.

Préciser les conventions retenues pour les bornes des intervalles.
3. Les variables `Pclass` et `Fare2` sont-elles indépendantes ?
Étudier leur distribution conjointe à l'aide d'un tableau de contingence.
On pourra utiliser `pd.crosstab()`.
Justifier votre réponse.
4. Calculer les taux de survie selon les catégories de `Fare2`.
Commenter les résultats.
5. Construire un deuxième classifieur naïf bayésien en utilisant uniquement :

$$X = (\texttt{Pclass}, \texttt{Fare2}).$$

Encoder les deux variables catégorielles de manière cohérente dans les ensembles d'apprentissage et de validation.

Entraîner un modèle `CategoricalNB`, puis calculer son taux de bonnes classifications sur `titanic_test.csv`.

Comparer ses performances avec celles du premier modèle utilisant le sexe et l'âge.

Quel modèle semble le plus performant ?

Commenter.

4 Modèles combinés

1. Construire un troisième classifieur naïf bayésien utilisant simultanément les quatre variables :

$$X = (\texttt{Child}, \texttt{Sex}, \texttt{Pclass}, \texttt{Fare2}).$$

   — Préparer et encoder les variables.
   — Entraîner le modèle sur l'ensemble d'apprentissage.
   — Évaluer ses performances sur l'ensemble de validation.
   — Comparer les trois modèles à l'aide du taux de bonnes classifications et des matrices de confusion.

   L'utilisation d'un plus grand nombre de variables améliore-t-elle nécessairement les performances du classifieur ?

   Commenter les résultats.

2. Essayer d'enrichir le modèle avec d'autres variables explicatives :
   — `Embarked` : port d'embarquement (`S` = Southampton, `C` = Cherbourg, `Q` = Queenstown) ;
   — `SibSp` : nombre de frères, sœurs et conjoints à bord ;
   — `Parch` : nombre de parents et d'enfants à bord ;
   — `Cabin` : numéro de cabine.

   Attention : certaines variables contiennent des valeurs manquantes ou des chaînes vides.

   Pour `Embarked`, remplacer les valeurs manquantes et les chaînes vides par une catégorie explicite `"NA"`.

   Appliquer un traitement cohérent aux deux ensembles de données.

   Pour les variables numériques, réfléchir à une éventuelle discrétisation avant d'utiliser `CategoricalNB`.

   Évaluer les performances des nouveaux modèles.

   Quelles variables semblent apporter une information supplémentaire utile pour prédire la survie ?

5 Synthèse et comparaison des modèles

Présenter les résultats obtenus dans un tableau comparatif contenant :
— les variables utilisées par chaque modèle ;
— le taux de bonnes classifications sur l'ensemble de validation ;
— les principales erreurs de classification.

Répondre aux questions suivantes :

1. Quel modèle obtient les meilleures performances ?
2. L'ajout de variables améliore-t-il systématiquement les résultats ?
3. L'hypothèse d'indépendance conditionnelle du classifieur naïf bayésien est-elle réaliste pour les variables étudiées ?
4. Quelles sont les principales limites de cette approche sur les données du Titanic ?