Apprentissage Statistique - TP 1

M2 EI2D & MATD – Le 22 sept 2025

Instructions : Préparez un rapport incluant le code source et vos résultats, et déposez-le sur Teams. Pas plus de 2 personnes par groupe. N'oubliez pas de mettre les 2 noms sur le rapport, ou de faire 2 rendus. La date limite du rendu TP est le 6 oct 2025

A Les Données

Dans cet exercice, on va utiliser un jeu de données génére par vous même.

1. Engendrez un tableau d'observations de la forme suivante :

$$\begin{pmatrix} (B,T,G) & (B,T,G) & (B,T,P) \\ (D,T,G) & (D,T,G) & (B,T,P) \\ (D,T,G) & (D,T,G) & (B,T,P) \\ (D,T,G) & (D,T,G) & (D,T,P) \\ (B,T,G) & (B,T,G) & (D,T,P) \\ (B,S,G) & (B,S,G) & (D,S,P) \\ (B,S,G) & (B,S,G) & (B,S,P) \\ (D,S,G) & (D,S,G) & (D,S,P) \end{pmatrix}$$

2. Dans l'exemple ci-dessus vous avez 8 rangés. Ecrivez une fonction Python qui vous permettent d'engendrer d'une manière aléatoire en utilisant une distribution uniforme un tableau de la même forme, mais avec n rangés et 3 colonnes.

3. On suppose que nous l'ensemble de données ainsi obtenu décrit les trois variables suivantes : Cheveux = B, D, où B=blond, D=dark. Hauteur = T, S, où T=tall, S=short. Pays = G, P, où G=Greenland, P=Poland.

B Question

Nous voulons répondre à la question suivante : si vous observez un nouvel individu grand ayant cheveux blonds, quel est son pays d'origine le plus probable?

B.1 Remarques :

1. Il s'agit d'écrire une fonction Python qui engendre une matrice ayant N lignes, dont chaque élément est constitué d'une triplet du type :$(X_1, X_2, X_3), X_i \neq X_j, X_i \in \{D, T, G\}$.

2. L'ensemble des fonctions du TP doivent être écrites par rapport à cette matrice crée par vous-même. Ne donnez pas des réponses par rapport à la matrice exemple de l'énoncé.

C Maximum a posteriori

1. Ecrivez une fonction Python qui donnera la solution maximum a posteriori (MAP) à la question, en utilisant le cadre naïf de Bayes.
2. Ecrivez une fonction Python qui donnera la solution maximum a posteriori (MAP) à la question, sans utiliser le cadre naïf de Bayes.

C.1 Remarques :

1. Dans ce cadre vous devons comparer $\mathbb{P}(G|B,T)$ avec $\mathbb{P}(P|B,T)$.
2. Sous l'hypothèse de Bayes naïf, on a
$$\mathbb{P}(G|B,T) = \frac{\mathbb{P}(B,T|G)\mathbb{P}(G)}{\mathbb{P}(B,T)}$$
et un calcul analogue pour $\mathbb{P}(P|B,T)$.
3. En conclusion on doit estimer $\mathbb{P}(B,T|G), \mathbb{P}(G), \mathbb{P}(B,T)$ et $\mathbb{P}(P)$
4. A titre d'exemple $\mathbb{P}(T|G) = \frac{5}{8}$ et $\mathbb{P}(G) = \frac{2}{3}$.
5. Sans l'hypothèse de Bayes naïf nous devons estimer $\mathbb{P}(B,T|G)$ et $\mathbb{P}(B,T|P)$ à partir de l'ensemble d'apprentissage fourni.

D Maximum de vraisemblance

1. Ecrivez une fonction Python qui donnera la solution de maximum de vraisemblance (MLE) à la question, en utilisant le cadre naïf de Bayes.
2. Ecrivez une fonction Python qui donnera la solution de maximum de vraisemblance (MLE) à la question, sans utiliser le cadre naïf de Bayes.

D.1 Remarques :

1. La réponse de MLE repose uniquement sur la comparaison des termes de vraisemblance. Par conséquent, nous devons comparer $\mathbb{P}(B,T|G)$ avec $\mathbb{P}(B,T|P)$.
2. A titre d'exemple sous l'hypothèse de Bayes naïf (NB), dans le cadre de la matrice exemple on obtient :
$$\mathbb{P}(B,T|G) = \mathbb{P}(B|G)\mathbb{P}(T|G) = \frac{8}{16} \cdot \frac{10}{16} = \frac{5}{16}$$
3. A titre d'exemple sans l'hypothèse de Bayes naïf (NB), nous devons comparer $\mathbb{P}(B,T|G)$ avec $\mathbb{P}(B,T|P)$ et l'on obtient $\mathbb{P}(B,T|G) = \frac{2}{8}$.

E Point de vue continu

Dans cette partie on suppose que la mesure estimée de la couleur des cheveux est continue donnée par une valeur appelée intensité variant entre $(0, 1)$ représentant l'intensité de la couleur de cheveux allant de B à D, où B=blond, D=dark.

1. Engendrez un tel jeu de données via une fonction Python.
2. Expliquer comment vous résoudriez la même question dans ce contexte.
3. Quelles sont les modifications à faire dans les fonctions Python précédentes afin de répondre à la même questions dans ce contexte.